

Laporan Teks Analitik

Nama : Risfi Ayu Sandika

NIM : 24917035

Mata Kuliah : Teks Analitik

Berkembangnya teknologi secara cepat memberikan kesempatan untuk pengguna melakukan ulasan terhadap suatu teknologi tertentu. Ulasan yang dilakukan oleh pengguna yaitu opini dan pengalaman pengguna itu sangat berharga bagi perusahaan dalam meningkatkan kualitas layanan. Tetapi dengan jumlah data yang sangat besar membuat analisis manual menjadi tidak efisien dan memakan banyak waktu. Text analytic merupakan solusi untuk mengolah informasi penting pada teks secara otomatis dan efisien. Salah satunya adalah text classification terkhusus sentiment analysis yaitu mengklasifikasikan teks ke dalam sentimen yaitu positif, negatif dan netral. Sehingga tugas akhir ini melakukan text classification berupa sentiment analysis dengan menggunakan dataset ulasan gojek yang didapatkan pada google play store (kaggle) berjumlah 225002 terdiri dari 5 kolom yaitu :

1. Username yaitu nama pengguna yang melakukan ulasan pada gojek
2. Content yaitu isi ulasan yang diberikan pengguna/username terkait gojek
3. Score yaitu nilai/score yang diberikan pengguna/username terkait penilaian gojek yang mana terdiri dari 1-5 dan 5 merupakan nilai tertinggi
4. At yaitu tanggal atau waktu pengguna mengunggah ulasan gojek
5. AppVersion yaitu versi aplikasi yang diberikan oleh pengguna yang memberikan ulasan

Jumlah kelas terdiri dari 3 yaitu :

Kelas	Score	Deskripsi
Negative	1-2	Ulasan keluhan / tidak puas
Neutral	3	Ulasan netral
Positive	4-5	Ulasan puas

Sample Dataset :

```
[1] import pandas as pd
df = pd.read_csv("gokjekAppReviewV4.0.0-V4.9.3_Cleaned.csv")
df.head()
```

	userName	content	score	at	appVersion
0	Yuga Edit	akun gopay saya di blok	1	2022-01-21 10:52:12	4.9.3
1	ff burik	Lambat sekali sekarang ini bossku apk gojek g...	3	2021-11-30 15:40:38	4.9.3
2	Anisa Suci Rahmayulani	Kenapa sih dari kemarin sy buka aplikasi gojek...	4	2021-11-29 22:58:12	4.9.3
3	naoki yakuza	Baru download gojek dan hape baru trus ditop u...	1	2022-09-03 15:21:17	4.9.3
4	Trio Sugianto	Mantap	5	2022-01-15 10:05:27	4.9.3

```
[1] df.shape
(225002, 5)
```

```

() df.isnull().sum()
0
username 0
content 2
score 0
at 0
appVersion 0
dtype: int64

() df = df.dropna(subset=["content"])

()
def map_sentiment(score):
    if score <= 2:
        return "negative"
    elif score == 3:
        return "neutral"
    else:
        return "positive"


df["sentiment"] = df["score"].apply(map_sentiment)

```

username	content	score	at	appVersion
Yuga Edit	akun gopay saya di blok	1	2022-01-21 10:52:12	4.9.3
ff burik	Lambat sekali sekarang ini bosssku apk gojek gk kaya dulu	3	2021-11-30 15:40:38	4.9.3
Anisa Suci Rahmayuliani	Kenapa sih dari kemarin sy buka aplikasi gojek malah keluar sendiri terus Saya kasih bintang 2 dulu kalo sudah normal sy kasih bintang 7	4	2021-11-29 22:58:12	4.9.3

naoki yakuza	Baru download gojek dan hape baru trus ditop u gopay transaksi dialfamart transaksi bloked transaksilapora n di pusat bantuan gak jelas yang ditanyakan apa jawaban lainlama lama gojek dikelola Tokopedia udah nyimpangapa gojek anak bangsa seperti dulu apa punya Tokopedia	1	2022-09-03 15:21:17	4.9.3
Trio Sugianto	Mantap	5	2022-01-15 10:05:27	4.9.3
Arlan Ramlan	Bagus	4	2022-02-01 5:50:40	4.9.3
Slamet Hariyanto	Coba dulu	2	2021-12-10 22:40:45	4.9.3
Hasan Thio	Ok	5	2022-02-01 3:07:45	4.9.3
RAFI BADZLIN	Gimana ini kak pin saya salah terus padahal udah di ubah masih salah	1	2022-12-17 8:56:52	4.9.3

Distribusi kelas sentimen :



```
[ ] def map_sentiment(score):  
    if score <= 2:  
        return "negative"  
    elif score == 3:  
        return "neutral"  
    else:  
        return "positive"  
  
df["sentiment"] = df["score"].apply(map_sentiment)  
  
[ ] df["sentiment"].value_counts()  
...      count  
sentiment  
positive 161369  
negative  54171  
neutral   9460  
dtype: int64
```

Ini merupakan gambar visualisasi dari distribusi kelas pada dataset ulasan gojek yang mana jumlah data sebagai berikut :

1. Positif : 161369
2. Negatif : 54171

3. Neutral : 9460

Selanjutnya dilakukan tahapan preprocessing sebagai berikut :

1. Dilakukan handling missing value pada setiap kolom untuk mengecek nilai kosong

```
[ ] df.isnull().sum()
...      0
  userName  0
   content  2
    score  0
     at    0
  appVersion  0
dtype: int64

[ ] df = df.dropna(subset=["content"])
```

Kemudian setelah melakukan pengecekan ditemukan 2 data kosong pada kolom content dan data tersebut dihapus karena content atau ulasan merupakan fitur utama pada ulasan

2. Dilakukan label encoding karena sentiment teks berupa (negatif, positif dan neutral) maka dikonversi menjadi label numerik menggunakan labelencoder

```
[ ] df = df[["content", "sentiment"]]
df.head()

   content sentiment
0  akun gopay saya di blok    negative
1  Lambat sekali sekarang ini bosssku apk gojek g...    neutral
2  Kenapa sih dari kemarin sy buka aplikasi gojek...    positive
3  Baru download gojek dan hape baru trus ditop u...    negative
4  Mantap                    positive

[ ] from sklearn.preprocessing import LabelEncoder

label_encoder = LabelEncoder()
df["label"] = label_encoder.fit_transform(df["sentiment"])

label_encoder.classes_
array(['negative', 'neutral', 'positive'], dtype=object)
```

- a. Negatif = 0
 - b. Neutral = 1
 - c. Positif = 2
3. Dilakukan pembagian dataset, dataset dibagi menjadi :

```
[ ] from sklearn.model_selection import train_test_split

train_df, temp_df = train_test_split(
    df,
    test_size=0.30,
    random_state=42,
    stratify=df["label"]
)

val_df, test_df = train_test_split(
    temp_df,
    test_size=0.50,
    random_state=42,
    stratify=temp_df["label"]
)

len(train_df), len(val_df), len(test_df)

... (157500, 33750, 33750)
```

- a. Training : 70% = 157500
- b. Validation : 15% = 33750
- c. Testing : 15% = 33750

4. Dilakukan tokenisasi menggunakan tokenizer dari indobert
indobenchmark/indobert-base-p1 dengan parameter :

```
{ }  
from transformers import AutoTokenizer  
  
tokenizer_indobert = AutoTokenizer.from_pretrained(  
    "indobenchmark/indobert-base-p1"  
)  
  
/usr/local/lib/python3.12/dist-packages/huggingface_hub/utils/_auth.py:94: UserWarning:  
The secret 'HF_TOKEN' does not exist in your Colab secrets.  
To authenticate with the Hugging Face Hub, create a token in your settings tab (https://huggingface.co/settings/tokens), set it as secret in your Google Colab and restart your session.  
You will be able to reuse this secret in all of your notebooks.  
Please note that authentication is recommended but still optional to access public models or datasets.  
warnings.warn(  
tokenizer_config.json: 100% ██████████ 2.00/2.00 [00:00<00:00, 179B/s]  
config.json: 1.53k/? [00:00<00:00, 179kB/s]  
vocab.txt: 229k/? [00:00<00:00, 20.1MB/s]  
special_tokens_map.json: 100% ██████████ 112/112 [00:00<00:00, 14.6kB/s]  
  
{ }  
def tokenize_function(examples, tokenizer):  
    return tokenizer(  
        examples["content"],  
        padding="max_length",  
        truncation=True,  
        max_length=128  
    )
```

- a. Padding : max_length
- b. Truncation : true
- c. Maximum sequence length : 128 token

5. Dilakukan pemilihan model yang digunakan yaitu IndoBERT Base
(indobenchmark/indobert-base-p1) alasan atas pemilihan model tersebut ialah :

- a. Dilatih untuk bahasa indonesia (sesuai dengan dataset)
- b. Tersedia secara publik di hugging face model hub
- c. Performa baik pada NLP berbahasa indonesia

Model ini digunakan full fine-tuning dimana seluruh parameternya diperbarui selama proses training.

6. Dilakukan full fine-tuning yaitu seluruh parameter pre-trained language model diperbarui selama proses training, pemilihan full fine tuning karena :

- a. Dataset yang memiliki ukuran yang sangat besar sehingga resiko overfitting relatif lebih kecil
- b. Model menyesuaikan representasi bahasa secara optimal terhadap ulasan
- c. Memberikan performa yang baik

Full fine tuning dilakukan menggunakan library hugging face transformers sebagai berikut :

- a. Model menggunakan AutoModelForSequenceClassification dengan jumlah label sesuai kelas sentiment

```
from transformers import AutoModelForSequenceClassification  
  
model = AutoModelForSequenceClassification.from_pretrained(  
    "indobenchmark/indobert-base-p1",  
    num_labels=3  
)  
  
pytorch_model.bin: 100% ██████████ 498M/498M [00:02<00:00, 247MB/s]  
  
Some weights of BertForSequenceClassification were not initialized from the model checkpoint at indobenchmark/indobert-base-p1 and are newly initialized: ['classifier.bias', 'classifier.weight']  
You should probably TRAIN this model on a down-stream task to be able to use it for predictions and inference.
```

- b. Huggingface trainer melakukan otomatis yaitu :

- 1. Membuat optimizer AdamW
- 2. Memasukkan model.parameters()

3. Menghitung loss
4. Melakukan backpropagation

```
from transformers import TrainingArguments

training_args = TrainingArguments(
    output_dir="./results_indobert",
    eval_strategy="epoch",
    save_strategy="epoch",
    learning_rate=2e-5,
    per_device_train_batch_size=16,
    per_device_eval_batch_size=16,
    num_train_epochs=3,
    weight_decay=0.01,
    logging_dir="./logs",
)
```

- c. Ketika trainer.train() dipanggil maka :
1. Forward pass ke indobERT
 2. Hitung loss
 3. Backward pass
 4. Update seluruh parameter model

```
from transformers import Trainer

trainer = Trainer(
    model=model,
    args=training_args,
    train_dataset=train_indobert,
    eval_dataset=val_indobert,
    compute_metrics=compute_metrics
)
```

```
trainer.train()
```

```
/usr/local/lib/python3.12/dist-packages/notebook/notebookapp.py:191: SyntaxWarning: invalid escape sequence '\'
```


```
wandb: (1) Create a W&B account
wandb: (2) Use an existing W&B account
wandb: (3) Don't visualize my results
wandb: Enter your choice: 3
wandb: You chose "Don't visualize my results"
Tasking run with wandb version 0.23.1
W&B syncing is set to "offline" in this directory. Run 'wandb online' or set WANDB_MODE=online to enable cloud syncing.
Run data is saved locally in /content/wandb/offline-run-20260101_234520-v2kdrf9w
[29532/29532 44.05, Epoch 3/3]
```

Epoch	Training Loss	Validation Loss	Accuracy	Precision	Recall	F1
1	0.295400	0.306412	0.898667	0.887917	0.898667	0.882500
2	0.262900	0.306929	0.906044	0.904369	0.906044	0.890390
3	0.230100	0.334988	0.899822	0.884328	0.899822	0.889962

```
TrainOutput(global_step=29532, training_loss=0.2768384185121214, metrics={'train_runtime': 2652.5821, 'train_samples_per_second': 178.128, 'train_steps_per_second': 11.133, 'total_flos': 3.188027246912e+16, 'train_loss': 0.2768384185121214, 'epoch': 3.0})
```

- d. Alur full fine tuning yaitu :
1. Input teks yaitu tokenizer indobERT
 2. Token ID yaitu model indobERT
 3. Ouput logits yaitu softmax
 4. Hitung loss
 5. Update seluruh parameter model

- e. Ini merupakan hasil evaluasi dari model indoBERT yang telah melakukan full fine tuning menggunakan dataset yang tersedia dapat dijelaskan sebagai berikut :
1. Kelas negatif : 7052 ulasan negatif dapat diprediksi benar sebagai negatif, 256 salah prediksi sebagai netral, 818 salah prediksi sebagai positif
 2. Kelas neutral : 147 benar diprediksi, 743 salah prediksi menjadi negatif dan 538 slaah prediksi menjadi positif (penyebab dikarenakan jumlah data neutral jauh lebih sedikit dibanding yang lain)
 3. Kelas positif : 23107 diprediksi benar, 972 diprediksi salah menjadi negatif dan 126 salah prediksi sebagai netral



7. Dilakukan hyperparameter dilakukan untuk eksplorasi yaitu :

1. Baseline :
 - a. LR 2e-5
 - b. Batch Size 16
2. Learning Rate diperkecil :
 - a. LR 1e-5
 - b. Batch Size 16
3. Batch Size diperkecil :
 - a. LR 2e-5
 - b. Batch size 8

Justifikasi :

1. Learning rate yang kecil dapat membantu stabilitas training
2. Batch size yang kecil berpotensi untuk generalisasi model meskipun proses menjadi lambat

```

from transformers import TrainingArguments, Trainer

training_args_lr_small = TrainingArguments(
    output_dir='./results_lr_small',
    eval_strategy='epoch',
    save_strategy='epoch',
    learning_rate=5e-5, # batch kecil
    per_device_train_batch_size=16,
    per_device_eval_batch_size=16,
    num_train_epochs=3,
    weight_decay=0.01,
    logging_dir='./logs_lr_small',
    load_best_model_at_end=True
)

trainer_lr_small = Trainer(
    model=load_indobert_model(),
    args=training_args_lr_small,
    train_dataset=train_indobert,
    eval_dataset=eval_indobert,
    compute_metrics=compute_metrics
)

trainer_lr_small.train()

eval_lr_small = trainer_lr_small.evaluate(test_indobert)
eval_lr_small

Some weights of BertForSequenceClassification were not initialized from the model checkpoint at indobenchmark/indobert-base-pl and are newly initialized: ['classifier.bias', 'classifier.weight']
You should probably TRAIN this model on a down-stream task to be able to use it for predictions and inference.
[29532/29532 44.14, Epoch 3/3]

Epoch Training Loss Validation Loss Accuracy Precision Recall F1
1 0.287100 0.295981 0.904444 0.889759 0.904444 0.890823
2 0.257100 0.307442 0.905333 0.892832 0.905333 0.890380
3 0.232900 0.327321 0.901096 0.885580 0.901096 0.891005

[21192/110 00:59]
{'eval_loss': 0.29446548223495483,
 'eval_accuracy': 0.9039181878784,
 'eval_precision': 0.8894574889893751,
 'eval_recall': 0.9039787878787878,
 'eval_f1': 0.88949171181113,
 'eval_runtime': 59.7885,
 'eval_samples_per_second': 564.49,
 'eval_steps_per_second': 35.293,
 'epoch': 3.0}

```

```

training_args_bs_small = TrainingArguments(
    output_dir='./results_bs_small',
    eval_strategy='epoch',
    save_strategy='epoch',
    learning_rate=2e-5, # batch size kecil
    per_device_train_batch_size=8,
    per_device_eval_batch_size=8,
    num_train_epochs=3,
    weight_decay=0.01,
    logging_dir='./logs_bs_small',
    load_best_model_at_end=True
)

trainer_bs_small = Trainer(
    model=load_indobert_model(),
    args=training_args_bs_small,
    train_dataset=train_indobert,
    eval_dataset=eval_indobert,
    compute_metrics=compute_metrics
)

trainer_bs_small.train()

eval_bs_small = trainer_bs_small.evaluate(test_indobert)
eval_bs_small

Some weights of BertForSequenceClassification were not initialized from the model checkpoint at indobenchmark/indobert-base-pl and are newly initialized: ['classifier.bias', 'classifier.weight']
You should probably TRAIN this model on a down-stream task to be able to use it for predictions and inference.
[59064/59064 53.03, Epoch 3/3]

Epoch Training Loss Validation Loss Accuracy Precision Recall F1
1 0.359900 0.320860 0.902874 0.901524 0.902874 0.886774
2 0.301400 0.361697 0.904415 0.901443 0.904415 0.888868
3 0.286600 0.368827 0.901452 0.883778 0.901452 0.889626

[42194/219 01:00]
{'eval_loss': 0.3185221552848816,
 'eval_accuracy': 0.9021925925925925,
 'eval_precision': 0.8865802878988074,
 'eval_recall': 0.9021925925925925,
 'eval_f1': 0.8855812465615764,
 'eval_runtime': 68.1659,
 'eval_samples_per_second': 495.087,
 'eval_steps_per_second': 61.89,
 'epoch': 3.0}

```

8. Hasil dari evaluasi model yaitu sebagai berikut :

```

import pandas as pd

comparison_df = pd.DataFrame([
    {
        "Experiment": "Baseline (LR=5e-5, BS=16)",
        "Accuracy": test_results["eval_accuracy"],
        "Precision": test_results["eval_precision"],
        "Recall": test_results["eval_recall"],
        "F1": test_results["eval_f1"]
    },
    {
        "Experiment": "LR kecil (LR=5e-5, BS=16)",
        "Accuracy": eval_lr_small["eval_accuracy"],
        "Precision": eval_lr_small["eval_precision"],
        "Recall": eval_lr_small["eval_recall"],
        "F1": eval_lr_small["eval_f1"]
    },
    {
        "Experiment": "BS kecil (LR=2e-5, BS=8)",
        "Accuracy": eval_bs_small["eval_accuracy"],
        "Precision": eval_bs_small["eval_precision"],
        "Recall": eval_bs_small["eval_recall"],
        "F1": eval_bs_small["eval_f1"]
    }
])

comparison_df

Experiment Accuracy Precision Recall F1
0 Baseline (LR=5e-5, BS=16) 0.897956 0.882984 0.897956 0.888495
1 LR kecil (LR=5e-5, BS=16) 0.903070 0.889457 0.903070 0.889949
2 BS kecil (LR=2e-5, BS=8) 0.902193 0.886591 0.902193 0.885581

```

Dari eksperimen ini dapat dilihat bahwa learning rate lebih kecil memberikan performa terbaik secara keseluruhan.

9. Analisis yang dapat di tarik adalah :

- a. IndoBERT efektif untuk analisis sentiment bahasa indonesia
- b. Hyperparameter tuning berpengaruh signifikan terhadap performa model
- c. Learning rate yang lebih kecil memberikan training yang lebih stabil
- d. Data class mempengaruhi performa jelas minoritas (neutral)

10. Kesimpulan yang dapat di tarik adalah :

- a. IndoBERT dengan full fine tuning mampu mencapai akurasi diatas 90%
- b. Pengaturan hyperparameter sangat penting
- c. Dataset ulasan gojek dapat digunakan untuk analisis sentimen